

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)»

(МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления»

Кафедра ИУ5 «Системы обработки информации и управления»

Курс «Технологии машинного обучения»

Отчет по лабораторной работе №4

Выполнила:

студент группы ИУ5-63Б

Латыпова К.Н.

Проверил:

преподаватель каф. ИУ5

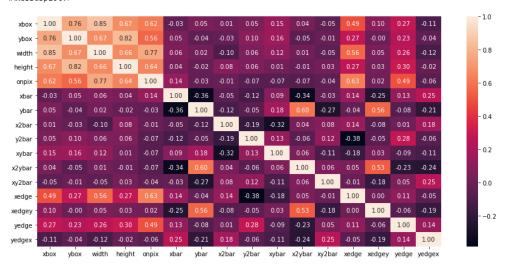
Гапанюк Ю.Е.

Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите следующие модели:
 - о одну из линейных моделей;
 - SVM;
 - о дерево решений.
- 5. Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей.

Текст программы и экранные формы:

```
ЛР4
    B [1]: import numpy as np
           import pandas as pd
from typing import Dict, Tuple
           import seaborn as sns
import matplotlib.pyplot as plt
           %matplotlib inline
           from sklearn.impute import SimpleImputer
           import warnings
           from sklearn.pipeline import Pipeline
from sklearn.preprocessing import PolynomialFeatures
           from sklearn.metrics import confusion_matrix, precision_score, recall_score, f1_score, classification_report from sklearn.linear_model import LinearRegression
           warnings.simplefilter("ignore")
    B [2]: # чтение обучающей выборки data = pd.read_csv('letterdata.csv')
          data.head()
Out[2]: letter xbox ybox width height onpix xbar ybar x2bar y2bar xybar x2ybar xy2bar xedge xedgey yedge yedgex
        0 T 2 8 3 5 1 8 13 0 6 6 10 8 0 8 0
                                                                                                       8
            I 5 12 3 7 2 10
                                                5
                                                     5 4
                                                                13
                                                                      3
        2 D 4 11 6 8 6 10 6 2 6 10 3 7 3 7
                 7 11 6 6 3
                                            5
                                                     4 6 4 4
                                                                           10
                                                                                  6 10
        4 G 2 1 3 1
 B [3]: from sklearn.model_selection import train_test_split
        from sklearn.preprocessing import LabelEncoder
 В [4]: #Построим корреляционную матрицу
        fig, ax = plt.subplots(figsize=(15,7))
        sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```



```
B [5]: X = data.drop(['width', 'letter'], axis = 1)
Y = data.width
print('Входные данные:\n\n', X.head(), '\n\nВыходные данные:\n\n', Y.head())
```

Входные данные:

```
xbox
     vbox
           height onpix xbar
                                ybar
                                      x2bar y2bar
                                                   xybar
                                                          x2ybar
                                                                 xv2bar \
                                         0
                                                      6
                                                             10
       8
                                13
                                               6
      12
                           10
                                                4
                                                     13
                                                                      9
 4
      11
               8
                      6
                           10
                                  6
                                         2
                                                6
                                                     10
      11
                                                6
                                                                     10
                            8
```

	xedge	xedgey	yedge	yedgex
0	0	8	0	8
1	2	8	4	10
2	3	7	3	9
3	6	10	2	8
4	1	7	5	10

Выходные данные:

Name: width, dtype: int64

Входные параметры обучающей выборки:

	xbox	ybox	height	onpix	xbar	ybar	x2bar	y2bar	xybar	x2ybar	١
17964	3	6	5	5	9	8	5	5	7	6	
11632	2	1	1	1	6	9	8	4	7	5	
10869	4	9	7	3	8	7	8	5	10	5	
9179	4	10	8	2	7	9	0	8	14	6	
8871	4	8	6	2	8	5	4	6	15	6	

	xy2bar	xedge	xedgey	yedge	yedgex
17964	8	5	8	9	11
11632	8	2	7	4	11
10869	9	3	8	4	7
9179	6	0	10	2	7
8871	11	1	6	0	7

```
Входные параметры тестовой выборки:
```

```
xbox ybox height
                              onpix
                                     xbar
                                            ybar
                                                  x2bar
                                                          y2bar
                                                                  xybar
                                                                          x2ybar \
19134
          3
                 3
                          2
                                 1
                                             11
                                                      2
                                                                    11
                                                                             10
4981
                          4
                                        9
          3
                 5
                                 4
                                              6
                                                      3
                                                              6
                                                                    10
                                                                              5
16643
           4
                 8
                          5
                                 2
                                        3
                                              8
                                                      8
                                                              2
                                                                     7
                                                                              5
19117
          5
                          7
                10
                                 4
                                        4
                                             10
                                                      2
                                                              8
                                                                    11
                                                                             12
5306
           4
                 7
                          8
                                 5
                                        8
                                              7
                                                      6
                                                              4
                                                                     8
                                                                              7
       xy2bar
               xedge
                       xedgey
                                yedge
                                       yedgex
19134
             5
                                             5
                            11
                                    2
                    1
4981
                                             9
                    2
                             8
                                    5
16643
                                            10
            11
                    4
                             8
                                     3
19117
             9
                    3
                             9
                                    2
                                             6
5306
             9
                    3
                             8
                                     6
                                             8
```

Выходные параметры обучающей выборки:

```
17964 5
11632 2
10869 4
9179 5
8871 5
```

Name: width, dtype: int64

Выходные параметры тестовой выборки:

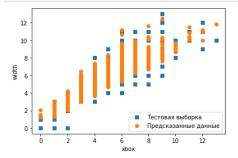
```
19134 4
4981 6
16643 4
19117 7
5306 4
```

Name: width, dtype: int64

```
B [7]: from sklearn.linear_model import LinearRegression from sklearn.metrics import mean_absolute_error, mean_squared_error, median_absolute_error, r2_score
```

```
B [8]: Lin_Reg = LinearRegression().fit(X_train, Y_train)
lr_y_pred = Lin_Reg.predict(X_test)
```

```
B [9]: plt.scatter(X_test.xbox, Y_test, marker = 's', label = 'Тестовая выборка')
plt.scatter(X_test.xbox, lr_y_pred, marker = 'o', label = 'Предсказанные данные')
plt.legend (loc = 'lower right')
plt.xlabel ('xbox')
plt.ylabel ('width')
plt.show()
```



SVM

```
B [10]: from sklearn.svm import SVC , LinearSVC from sklearn.datasets.samples_generator import make_blobs from matplotlib import pyplot as plt

B [11]: 

X , y = make_blobs(n_samples=125, centers=2, cluster_std=0.6, random_state=0) 

# KONUY, KON KNACMEPOB, CMAHD OMKN,
```

```
11]: X , y = make_blobs(n_samples=125, centers=2, cluster_std=0.6, random_state=0)
# κοπυν, κοπ κπασπεροθ, σπαнθ οπκπ,

train_X, test_X, train_y, test_y = train_test_split(X, y, test_size=40, random_state=0)

plt.scatter(train_X[:, 0], train_X[:, 1], c=train_y, cmap='winter')
```

```
Out[11]: <matplotlib.collections.PathCollection at 0x21c668162e0>
                                      1.5
                                                  2.5
               -0.5 0.0 0.5 1.0
                                            2.0
                                                        3.0
 B [12]: svc = SVC(kernel='linear')
svc.fit(train_X,train_y)
Out[12]: SVC(kernel='linear')
   B [13]: plt.scatter(train_X[:, 0], train_X[:, 1], c=train_y, cmap='winter')
            ax=plt.gca()
xlim=ax.get_xlim()
             ax.scatter(test_X[:, 0], test_X[:, 1], c=test_y, cmap='winter', marker='s')
             w= svc.coef_[0]
             a = -w[0]/w[1]
            a= -w[0]/w[1]
xx=np.linspace(xlim[0], xlim[1])
yy= a * xx - (svc.intercept_[0]/ w[1])
             plt.plot(xx, yy)
 Out[13]: [<matplotlib.lines.Line2D at 0x21c665dc5b0>]
             2
             1
  B [14]: pred_y = svc.predict(test_X)
  B [15]: confusion_matrix(test_y, pred_y)
Out[15]: array([[21, 0], [ 0, 19]], dtype=int64)
            Tree
  B [16]: from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor, export_graphviz from sklearn.tree import export_graphviz
            from sklearn import tree
            import re
B [17]: data = pd.read_csv('letterdata.csv')
X = data.drop(['width', 'letter', 'onpix', 'xbar', 'ybar', 'x2bar', 'xy2bar', 'xy2bar', 'xy2bar', 'xy2bar', 'xy2bar', 'xy2bar', 'xedge', 'xedge'
Y = data.width
         print('Входные данные:\n\n', X.head(), '\n\nВыходные данные:\n\n', Y.head())
         4
         Входные данные:
               xbox ybox height
                      12
                 5
                                  8
                       11
         4
         Выходные данные:
         1
               3
               6
```

Name: width, dtype: int64

```
В [18]: # Обучим дерево на всех признаках iris
                  clf = tree.DecisionTreeClassifier()
                  clf = clf.fit(X, Y)
B [19]: from IPython.core.display import HTML
                  from sklearn.tree.export import export_text
tree_rules = export_text(clf, feature_names=list(X.columns))
HTML('' + tree_rules + '')
      Out[19]: |--- xbox <= 3.50
                                    |--- xbox <= 2.50
                                            |--- xbox <= 1.50
                                                    |--- height <= 3.50
                                                           |--- xbox <= 0.50
                                                                     |--- ybox <= 0.50
                                                                             |--- height <= 0.50
                                                                              | |--- class: 1
                                                                         |--- height > 0.50
                                                                         | |--- class: 1
                                                                     |--- ybox > 0.50
                                                                              |--- height <= 1.50
                                                                                    |--- ybox <= 2.00
                                                                                       | |--- class: 0
                                                                                    |--- ybox > 2.00
                                                                                     | |--- class: 0
                                                                                         hoight \ 1 FO
         B [20]: tree.plot_tree(clf)
       Out[20]: [Text(103.96580247961957, 211.4, 'X[0] <= 3.5\ngini = 0.855\nsamples = 20000\nvalue = [195, 385, 1285, 1994, 3816, 4262, 364 1, 1946, 1418\n679, 237, 91, 39, 6, 4, 2]'),

Text(49.43657608695652, 199.32, 'X[0] <= 2.5\ngini = 0.766\nsamples = 8459\nvalue = [195, 385, 1284, 1955, 2961, 1503, 176,
                           0, 0, 0, 0, 0, 0, 0, 0)'),
Text(26.45445652173913, 187.24, 'X[0] <= 1.5\ngini = 0.728\nsamples = 4302\nvalue = [195, 385, 1283, 1577, 841, 21, 0, 0, 0,
                           (0, 0, 0)n0, 0, 0]'),
Text(6.388695652173913, 163.0799999999998, 'X[0] <= 0.5\ngini = 0.584\nsamples = 1169\nvalue = [54, 353, 655, 107, 0, 0, 0, 0, 0]
                           (0.30693217313, 103:05333333333333, [0] < 0.306111 - 0.3064(13amples - 11054(18amples - 13054(18amples - 130
                              Text(1.2939130434782609, 138.9200000000000002, 'X[2] <= 0.5\ngini = 0.483\nsamples = 76\nvalue = [31, 45, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]
                            0, 0, 0, 0, 0\n0, 0]'),
```